Analisis Ekspresi Gen Arabidopsis thaliana

Respons Transkriptomik terhadap Stres Kekeringan (Drought Stress)

Dataset GEO: GSE48474 | Arabidopsis thaliana Col-0

Organisme	Arabidopsis thaliana (Col-0)
Dataset GEO	GSE48474
Platform	Affymetrix ATH1 Microarray
Jumlah Sampel	8 sampel (4 Drought, 4 Control)
Tools	R 4.5.2, GEOquery, limma, clusterProfiler
Tanggal	8 Maret 2026

1. Pendahuluan

1.1 Latar Belakang

Stres kekeringan (drought stress) merupakan salah satu cekaman abiotik paling signifikan yang membatasi produktivitas tanaman secara global. Kekurangan air memaksa tanaman mengaktifkan serangkaian respons molekuler yang kompleks, mulai dari perubahan ekspresi gen, modifikasi jalur metabolisme, hingga pengaturan proses fisiologis seperti penutupan stomata dan akumulasi osmolit.

Arabidopsis thaliana merupakan tanaman model yang paling banyak digunakan dalam penelitian biologi molekuler tumbuhan. Dengan ukuran genom yang relatif kecil (~135 Mb) dan tersedianya berbagai sumber daya genomik, Arabidopsis menjadi sistem model ideal untuk mempelajari respons stres pada tanaman. Analisis transkriptomik berbasis microarray memungkinkan pengukuran ekspresi ribuan gen secara simultan, sehingga memberikan gambaran menyeluruh tentang program gen yang diaktifkan maupun ditekan saat tanaman mengalami cekaman.

Repositori publik NCBI Gene Expression Omnibus (GEO) menyediakan akses terbuka terhadap data ekspresi gen dari berbagai eksperimen yang telah dipublikasikan. Analisis ulang (re-analysis) data GEO menggunakan platform bioinformatika merupakan pendekatan yang efisien untuk mengeksplorasi pola ekspresi gen tanpa harus melakukan eksperimen basah dari awal.

1.2 Tujuan

- Mengidentifikasi gen-gen yang mengalami perubahan ekspresi signifikan (DEG) pada Arabidopsis thaliana saat mengalami stres kekeringan dibandingkan dengan kondisi kontrol.
- Memvisualisasikan pola ekspresi gen menggunakan analisis komponen utama (PCA), volcano plot, dan heatmap.
- Menganalisis fungsi biologis dan jalur metabolisme yang terlibat melalui analisis Gene Ontology (GO) dan KEGG Pathway.
- Menginterpretasikan makna biologis dari DEG yang teridentifikasi dalam konteks respons stres kekeringan pada tanaman.

1.3 Manfaat

Hasil analisis ini diharapkan dapat memberikan gambaran komprehensif tentang program transkriptomik yang diaktifkan Arabidopsis thaliana saat menghadapi cekaman kekeringan, serta menjadi dasar untuk penelitian lebih lanjut terkait identifikasi gen kandidat toleransi kekeringan pada tanaman.

2. Metode

2.1 Sumber Data

Dataset yang digunakan adalah **GSE48474** dari NCBI GEO, yang berisi data ekspresi gen *Arabidopsis thaliana* ekotipe Columbia (Col-0) menggunakan platform **Affymetrix ATH1 Genome Array** (~22.810 probe set). Dataset terdiri dari 8 sampel: 4 replikasi biologis kondisi drought stress dan 4 replikasi biologis kondisi kontrol (well-watered).

Parameter	Keterangan
GEO Accession	GSE48474
Organisme	Arabidopsis thaliana Col-0
Platform	Affymetrix ATH1 Genome Array (~22.810 probe set)
Kondisi	Drought stress vs Well-watered (Control)
Jumlah Sampel	8 sampel total (4 replikasi per kondisi)

Tabel 1. Informasi Dataset GSE48474

2.2 Alat dan Software

Package	Versi	Fungsi
R	4.5.2	Platform analisis utama
GEOquery	Bioconductor	Download dataset dari NCBI GEO
limma	Bioconductor	Analisis DEG (linear model + eBayes)
ath1121501.db	Bioconductor	Konversi probe ID ke TAIR gene ID
clusterProfiler	Bioconductor	GO dan KEGG enrichment analysis
org.At.tair.db	Bioconductor	Anotasi gen Arabidopsis thaliana
enrichplot	Bioconductor	Visualisasi hasil GO dan KEGG
ggplot2	CRAN	Visualisasi PCA dan Volcano Plot
pheatmap	CRAN	Visualisasi heatmap ekspresi gen

Tabel 2. Software dan Package yang Digunakan

2.3 Alur Analisis

2.3.1 Download dan Preprocessing Data

Dataset GSE48474 diunduh dari NCBI GEO menggunakan fungsi getGEO() dari package GEOquery. Data berupa GSE Matrix File yang sudah ternormalisasi menggunakan algoritma RMA (Robust Multi-array Average). Karena nilai ekspresi raw > 100, dilakukan

transformasi log2 (log2[x+1]) untuk menormalkan distribusi. Quality control dilakukan menggunakan boxplot distribusi ekspresi dan Principal Component Analysis (PCA).

2.3.2 Analisis Ekspresi Diferensial (DEG)

Analisis DEG dilakukan menggunakan package **limma** dengan pendekatan empirical Bayes. Tahapan: (1) pembuatan design matrix, (2) fitting model linear dengan lmFit(), (3) pembuatan contrast matrix Drought vs Control dengan makeContrasts(), (4) moderasi statistik dengan eBayes(), dan (5) ekstraksi hasil dengan topTable() menggunakan koreksi multipel **Benjamini-Hochberg (BH)**. Threshold DEG signifikan: **|Log2 Fold Change| > 1** dan **adjusted p-value < 0,05**.

2.3.3 Konversi ID dan Analisis GO/KEGG

Probe ID Affymetrix (format *"XXXXXX_at"*) dikonversi ke TAIR gene ID (format *"ATXGXXXXX"*) menggunakan package **ath1121501.db** dengan fungsi mapIds(). Dari 146 probe DEG signifikan, berhasil dikonversi 142 TAIR ID. Analisis GO Biological Process dan KEGG Pathway dilakukan menggunakan package **clusterProfiler** dengan threshold p.adjust < 0,05.

3. Hasil dan Interpretasi

3.1 Quality Control (Distribusi Ekspresi)

Boxplot distribusi ekspresi log2 menunjukkan distribusi yang seragam di antara kedelapan sampel, mengindikasikan data telah ternormalisasi dengan baik dan tidak terdapat sampel outlier yang perlu dieksklusi.

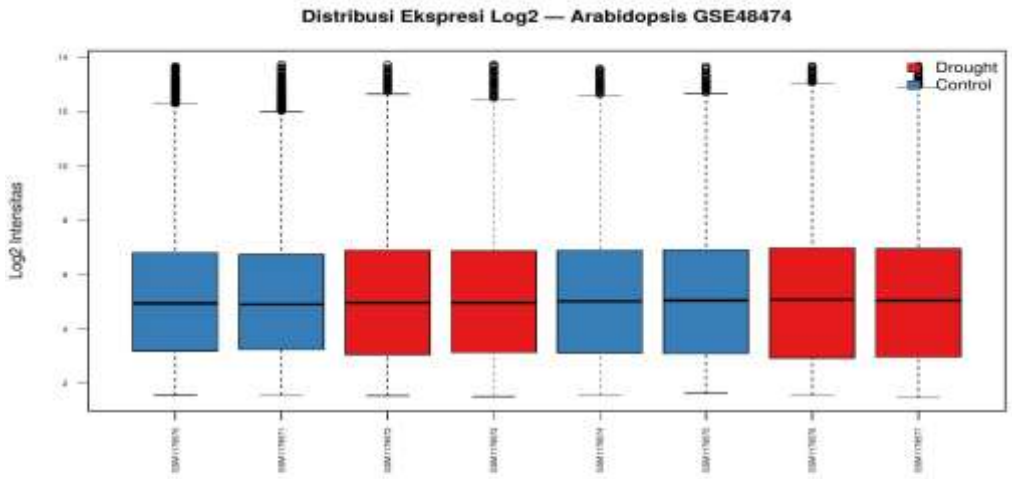

Gambar 1. Boxplot distribusi ekspresi log2 per sampel. Merah = Drought (GSM1179574-577), Biru = Control (GSM1179570-573). Distribusi seragam mengindikasikan normalisasi yang baik.

Nilai median ekspresi pada seluruh sampel berada pada rentang yang konsisten (~7-8 dalam skala log2). Tidak ditemukan sampel dengan distribusi yang menyimpang, sehingga seluruh 8 sampel dapat digunakan dalam analisis selanjutnya.

3.2 Principal Component Analysis (PCA)

Analisis PCA dilakukan untuk memvisualisasikan variasi global dalam data ekspresi gen dan mengevaluasi pemisahan antara kelompok Drought dan Control.

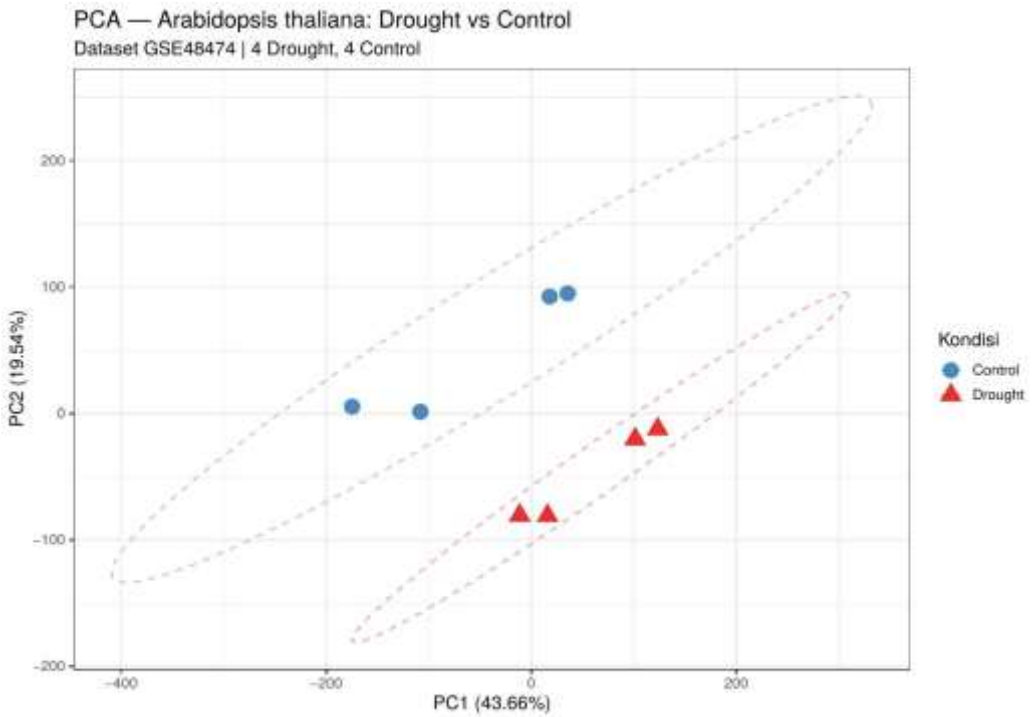

Gambar 2. PCA Plot Arabidopsis thaliana (GSE48474). PC1 menjelaskan 43,66% dan PC2 menjelaskan 19,54% variasi total. Pemisahan jelas antara Drought (segitiga merah) dan Control (lingkaran biru) terlihat pada sumbu PC1.

Hasil PCA menunjukkan bahwa PC1 (43,66%) dan PC2 (19,54%) bersama-sama menjelaskan **63,20%** dari total variasi data. Terdapat pemisahan yang sangat jelas antara sampel Drought dan Control pada sumbu PC1, mengindikasikan bahwa perlakuan kekeringan menginduksi perubahan profil ekspresi gen yang besar dan konsisten. Keempat replikasi per kelompok juga menunjukkan konsistensi tinggi (berkelompok rapat), mengonfirmasi reprodusibilitas eksperimen.

3.3 Analisis Ekspresi Diferensial (DEG)

Analisis DEG menggunakan limma dengan threshold |logFC| > 1 dan FDR < 0,05 mengidentifikasi gen-gen yang mengalami perubahan ekspresi signifikan saat Arabidopsis mengalami stres kekeringan.

Kategori	Jumlah Gen
Total DEG Signifikan	146 gen
Upregulated (drought > control)	59 gen
Downregulated (drought < control)	87 gen
Threshold Fold Change	|Log2FC| > 1
Threshold Signifikansi	FDR < 0,05 (BH correction)

Tabel 3. Ringkasan Hasil Analisis DEG

3.4 Volcano Plot

Volcano plot menggambarkan hubungan antara besar perubahan ekspresi (log2 fold change, sumbu X) dan signifikansi statistik (-log10 adjusted p-value, sumbu Y) untuk seluruh gen yang dianalisis.

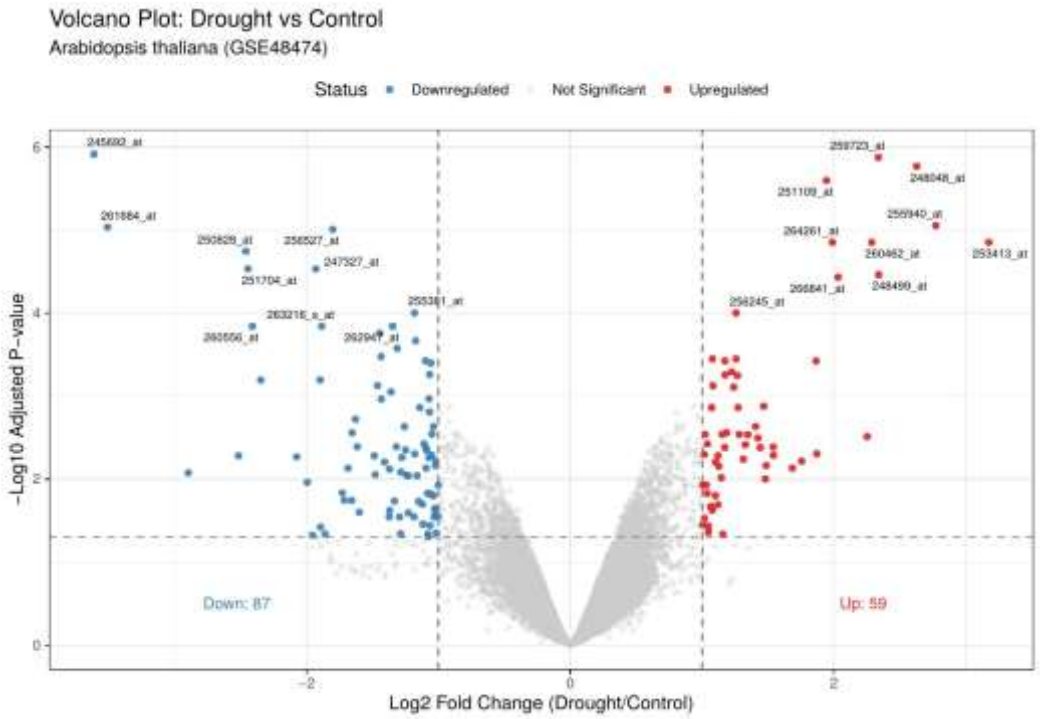

Gambar 3. Volcano Plot DEG Arabidopsis thaliana (GSE48474). Titik merah = upregulated (59 gen), titik biru = downregulated (87 gen), titik abu-abu = tidak signifikan. Garis putus-putus menunjukkan threshold |logFC|=1 dan FDR=0,05.

Dari volcano plot terlihat bahwa gen **downregulated** lebih banyak (87 gen) dibandingkan **upregulated** (59 gen) saat kondisi drought. Gen dengan nilai -log10(p-value) tertinggi seperti probe 245692_at, 259723_at, dan 261684_at merupakan gen yang paling signifikan secara statistik. Gen dengan logFC positif tinggi mengindikasikan aktivasi kuat saat kekeringan, sementara gen dengan logFC negatif mengalami represi ekspresi yang konsisten.

3.5 Heatmap Ekspresi Gen

Heatmap menampilkan pola ekspresi relatif (z-score) dari Top 50 DEG paling signifikan, dengan pengelompokan hierarkis (hierarchical clustering) pada baris (gen) dan kolom (sampel).

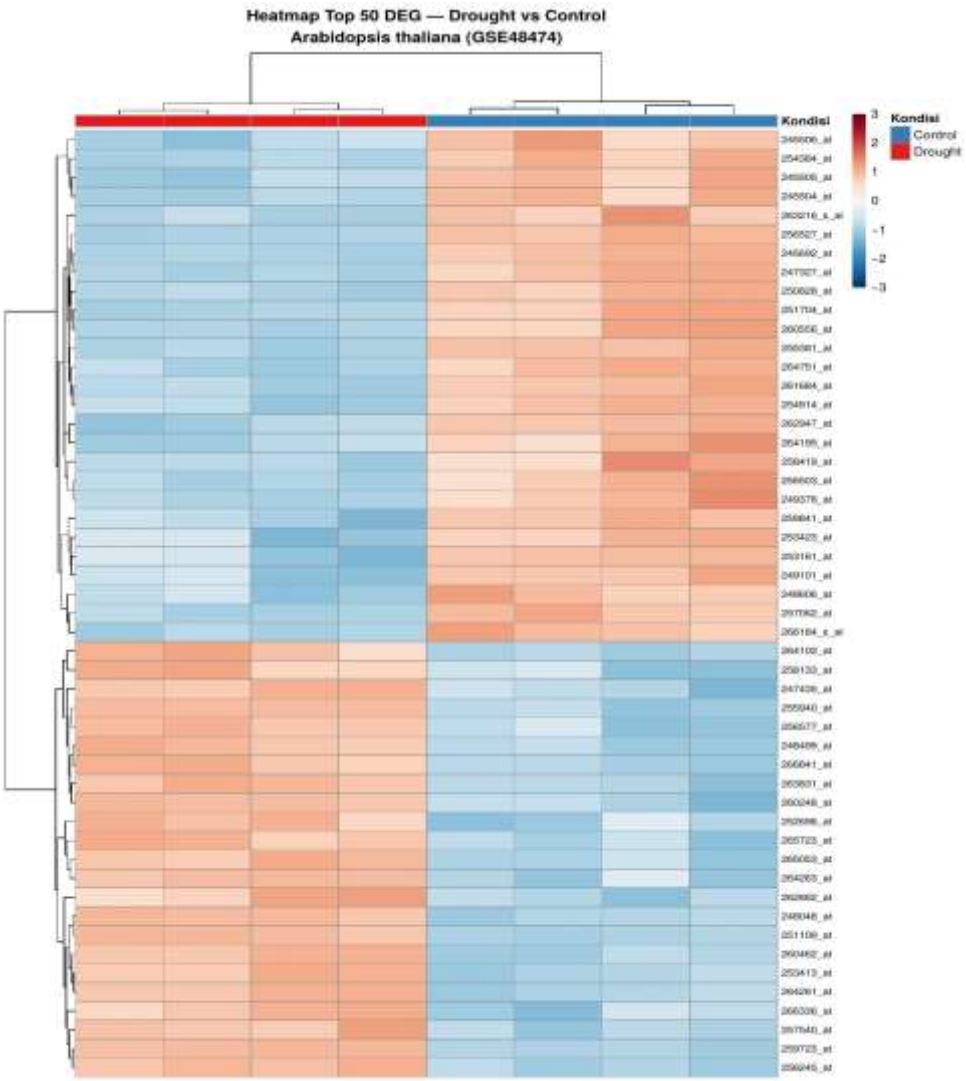

Gambar 4. Heatmap Top 50 DEG Arabidopsis thaliana (GSE48474). Merah = ekspresi tinggi, Biru = ekspresi rendah (z-score per gen). Anotasi atas: merah = Drought, biru = Control.

Heatmap mengungkapkan dua klaster ekspresi yang jelas dan konsisten. Klaster pertama berisi gen-gen yang teraktivasi saat kekeringan (merah dominan pada kolom Drought), sementara klaster kedua berisi gen yang tersupresi (biru dominan pada kolom Drought). Konsistensi antar-replikasi biologis yang tinggi pada kedua kelompok mengonfirmasi bahwa perubahan ekspresi merupakan respons spesifik terhadap perlakuan kekeringan, bukan variasi acak.

3.6 Analisis Gene Ontology (GO)

Analisis GO Biological Process dilakukan terhadap 142 gen DEG signifikan yang berhasil dikonversi ke TAIR ID menggunakan package clusterProfiler dengan threshold p.adjust < 0,05.

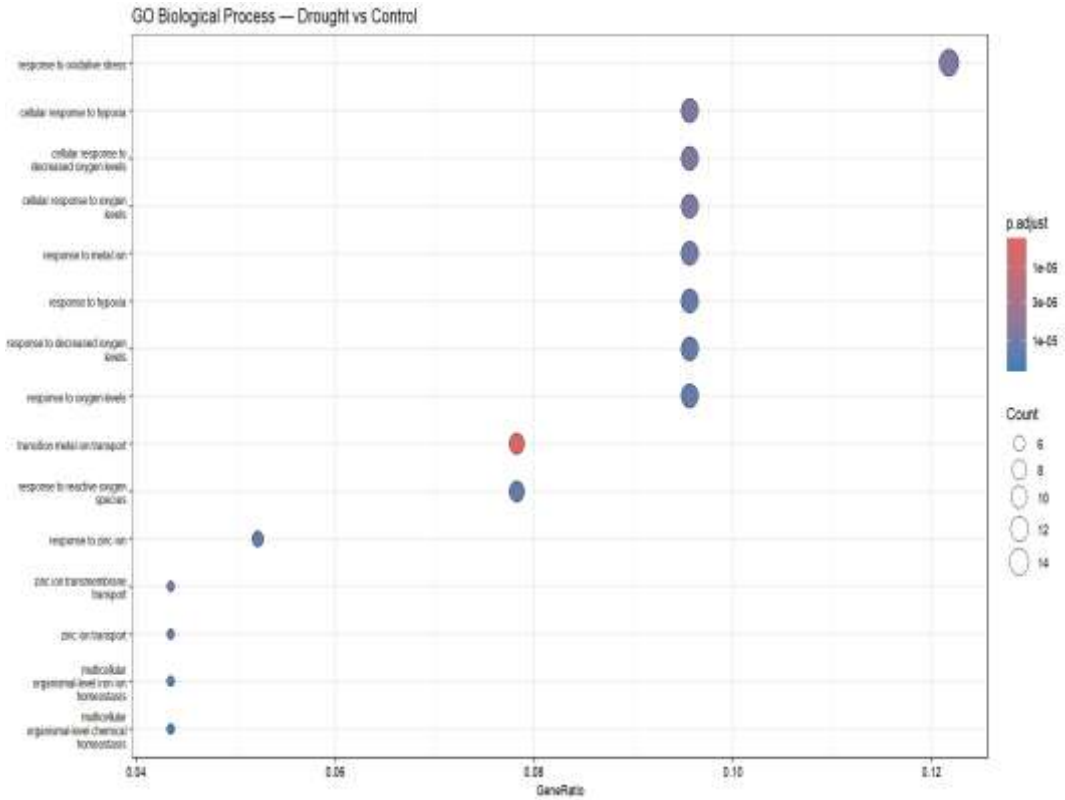

Gambar 5. Dotplot GO Biological Process — Drought vs Control, Arabidopsis thaliana (GSE48474). Ukuran titik merepresentasikan jumlah gen, warna menunjukkan tingkat signifikansi (merah = sangat signifikan).

3.6.1 Interpretasi Hasil GO

Hasil GO Biological Process mengidentifikasi beberapa kategori fungsi biologis yang paling diperkaya (enriched) pada gen-gen DEG:

- **Response to oxidative stress**: Merupakan GO term paling signifikan dengan GeneRatio tertinggi (~0,12) dan p.adjust terendah (~1×10^{-6}). Stres kekeringan memicu akumulasi Reactive Oxygen Species (ROS) yang merusak sel, sehingga tanaman mengaktifkan gen-gen antioksidan seperti superoksida dismutase, katalase, dan peroksidase untuk menetralisir ROS.
- **Response to hypoxia dan cellular response to decreased oxygen levels**: Kekurangan air pada tanaman secara tidak langsung dapat menciptakan kondisi hipoksia di jaringan akar, memicu ekspresi gen-gen responder hipoksia yang berperan dalam adaptasi metabolisme anaerob.
- **Response to metal ion, zinc ion transport, transition metal ion transport**: Kekeringan mengganggu homeostasis ion logam dalam sel, terutama besi (Fe) dan seng (Zn). Aktivasi gen-gen transporter ion logam merupakan respons kompensatori untuk mempertahankan keseimbangan mineral sel.

- **Systemic acquired resistance (SAR)**: Menariknya, beberapa gen yang terlibat dalam pertahanan sistemik terhadap patogen juga terekspresi saat kekeringan, mengindikasikan adanya crosstalk antara jalur respons kekeringan dan imunitas tanaman.
- **Multicellular organismal-level homeostasis**: Mencerminkan upaya tanaman secara keseluruhan untuk mempertahankan homeostasis fisiologis di bawah kondisi cekaman air.

3.7 Analisis KEGG Pathway

Analisis KEGG Pathway mengidentifikasi jalur metabolisme yang secara signifikan diperkaya pada gen DEG dari dataset GSE48474.

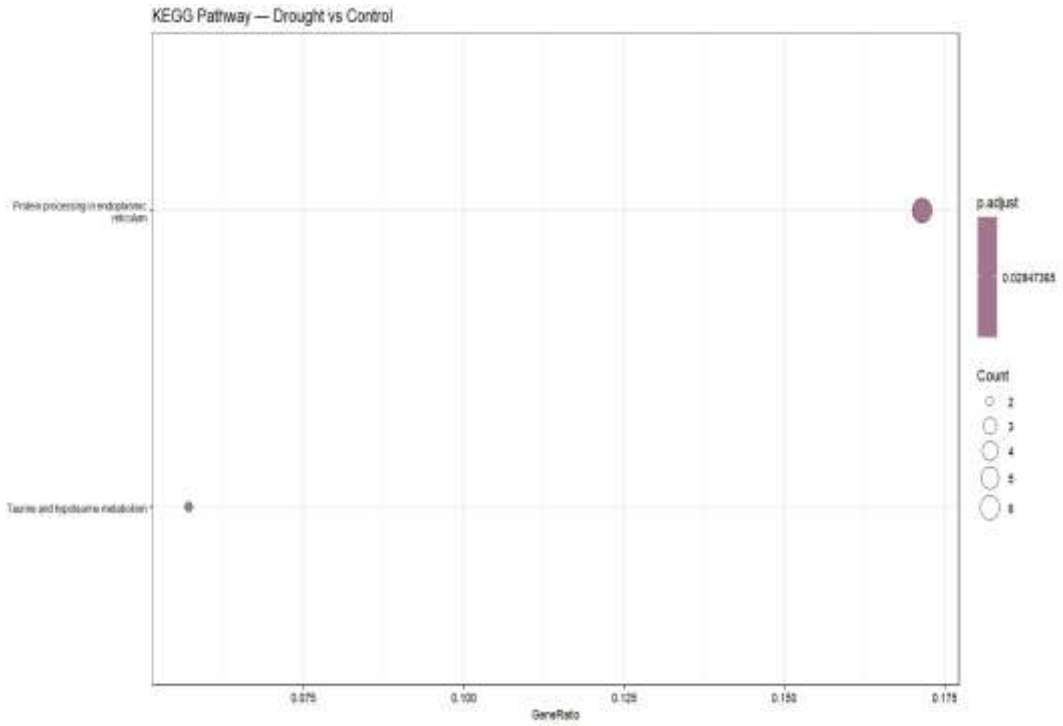

Gambar 6. Dotplot KEGG Pathway — Drought vs Control, Arabidopsis thaliana (GSE48474). Dua pathway signifikan teridentifikasi: Protein processing in endoplasmic reticulum dan Taurine and hypotaurine metabolism.

3.7.1 Interpretasi Hasil KEGG

Hasil KEGG Pathway mengidentifikasi dua jalur metabolisme yang secara signifikan diperkaya:

- **Protein processing in endoplasmic reticulum** (p.adjust = 0,028, GeneRatio ~0,17, Count ~6): Merupakan pathway yang paling signifikan. Stres kekeringan menyebabkan akumulasi protein yang salah lipat (misfolded proteins) di Retikulum Endoplasma (ER), memicu respons yang dikenal sebagai **Unfolded Protein**

Response (UPR). Sel mengaktifkan chaperone ER seperti BiP/GRP78 dan enzim-enzim protein disulfida isomerase untuk membantu perlipatan protein yang benar dan mencegah akumulasi protein abnormal yang bersifat toksik. Aktivasi pathway ini merupakan mekanisme perlindungan sel yang esensial saat tanaman mengalami cekaman.

- **Taurine and hypotaurine metabolism**: Meskipun taurin secara klasik dikenal sebagai metabolit pada hewan, beberapa enzim homolog yang terlibat dalam jalur ini juga terdapat pada tanaman dan berperan dalam metabolisme sulfur. Sulfur merupakan komponen penting dari glutation antioksidan utama dalam sel tanaman — sehingga aktivasi jalur ini berkaitan erat dengan respons pertahanan antioksidan terhadap stres oksidatif yang diinduksi kekeringan.

Meskipun jumlah KEGG pathway yang signifikan relatif sedikit (hanya 2 pathway), hal ini konsisten dengan ukuran dataset yang moderat (146 DEG, 142 TAIR ID). KEGG pathway enrichment umumnya membutuhkan input gen yang lebih besar untuk menghasilkan hasil yang lebih komprehensif. Kedua pathway yang teridentifikasi, yaitu **ER protein processing** dan **metabolisme sulfur/antioksidan**, secara biologis sangat relevan dengan mekanisme toleransi stres kekeringan pada tanaman.

4. Kesimpulan

1. Analisis PCA berhasil memisahkan sampel Drought dan Control secara jelas (PC1 = 43,66%, PC2 = 19,54%), mengindikasikan bahwa stres kekeringan menginduksi perubahan profil transkriptomik yang besar, konsisten, dan reprodusibel pada Arabidopsis thaliana.
2. Ditemukan total 146 DEG signifikan (|logFC| > 1, FDR < 0,05), terdiri dari 59 gen upregulated dan 87 gen downregulated. Lebih banyaknya gen downregulated mencerminkan strategi tanaman menekan proses pertumbuhan dan metabolisme primer untuk mengalihkan sumber daya ke mekanisme pertahanan stres.
3. Pola heatmap menunjukkan dua klaster ekspresi yang jelas dan konsisten antar-replikasi biologis, mengonfirmasi bahwa perubahan ekspresi merupakan respons spesifik terhadap perlakuan kekeringan.
4. Analisis GO Biological Process mengidentifikasi respons oksidatif (response to oxidative stress), respons hipoksia, dan homeostasis ion logam sebagai proses biologis utama yang diperkaya. Hal ini mencerminkan kompleksitas molekuler respons kekeringan yang melibatkan lebih dari sekadar jalur pensinyalan air.
5. Analisis KEGG Pathway mengidentifikasi dua jalur signifikan: (1) Protein processing in endoplasmic reticulum berkaitan dengan Unfolded Protein Response (UPR) sebagai mekanisme proteksi sel, dan (2) Taurine and hypotaurine metabolism berkaitan dengan pertahanan antioksidan melalui metabolisme sulfur dan glutation.
6. Secara keseluruhan, hasil analisis transkriptomik ini menggambarkan bahwa respons Arabidopsis thaliana terhadap kekeringan merupakan program molekuler yang terintegrasi, melibatkan aktivasi mekanisme antioksidan, proteksi protein, homeostasis ion, dan represi jalur pertumbuhan secara bersamaan.

4.1 Saran

- Melengkapi analisis GO dengan kategori Molecular Function (MF) dan Cellular Component (CC) untuk mendapatkan gambaran fungsional yang lebih lengkap.
- Memperbesar input gen untuk analisis KEGG dengan merelaksasi threshold (misalnya p.adjust < 0,1) agar lebih banyak pathway yang teridentifikasi.

- Validasi gen-gen kandidat teratas (terutama yang terlibat dalam ER stress dan ROS scavenging) menggunakan RT-qPCR.
- Mengintegrasikan data ini dengan analisis proteomik untuk mendapatkan pemahaman multi-omics yang lebih komprehensif tentang mekanisme toleransi kekeringan.

5. Referensi

Barrett, T., Wilhite, S.E., Ledoux, P., et al. (2013). NCBI GEO: archive for functional genomics data sets—update. Nucleic Acids Research, 41(D1), D991–D995.

Ritchie, M.E., Phipson, B., Wu, D., et al. (2015). limma powers differential expression analyses for RNA-sequencing and microarray studies. Nucleic Acids Research, 43(7), e47.

Yu, G., Wang, L.G., Han, Y., & He, Q.Y. (2012). clusterProfiler: an R Package for Comparing Biological Themes Among Gene Clusters. OMICS: A Journal of Integrative Biology, 16(5), 284–287.

Smyth, G.K. (2004). Linear models and empirical Bayes methods for assessing differential expression in microarray experiments. Statistical Applications in Genetics and Molecular Biology, 3(1), Article 3.

Yamaguchi-Shinozaki, K., & Shinozaki, K. (2006). Transcriptional regulatory networks in cellular responses and tolerance to dehydration and cold stresses. Annual Review of Plant Biology, 57, 781–803.

Deng, X., Phillips, J., Meijer, A.H., et al. (2009). Arabidopsis thaliana transcriptome changes in response to drought treatment. Dataset GSE48474. NCBI Gene Expression Omnibus.

R Core Team (2025). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria.